

SUBJECT: 3/9/2023

DATE: DR/mostafa

Section 1

(AI) كاء اصبع
Math Basics

Linear Algebra

يعامل مع المعادلات على أنها معادلات خطية

$$a_1 x_1 + a_2 x_2 + \dots + a_n x_n = y$$

$$A \cdot \underline{x} = \underline{y}$$

Matrix

الخطوات المطلوبات

$$3x_1 + 5x_2 = 12$$

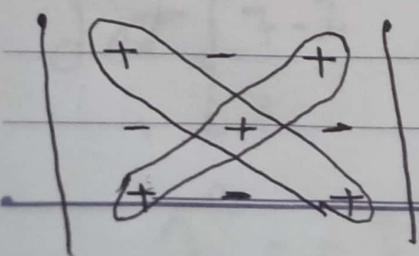
$$T A \cdot \underline{x} = T(\underline{y})$$

$$4x_1 + 3x_2 = 15$$

$$\begin{bmatrix} 3 & 5 \\ 4 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 12 \\ 15 \end{bmatrix}$$

$$\underline{x} = \underline{y}$$

$$\underline{x} = \frac{\underline{y}}{A}$$



Matrix Transposition (A^T)

$$A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix} \Rightarrow A^T = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{12} & a_{22} & a_{32} \end{bmatrix}$$

$$(AB)^T = B^T A^T \quad AB \neq BA$$

$$(A+B)^T = A^T + B^T \quad (AB)C = A(BC)$$

$$(2A)^T = 2A^T \quad (B+A)C = BC + AC$$

Symmetric Matrix = Transposition matrix

$$A = A^T$$

Orthogonal Matrix \rightarrow Transposition (cols)
inverse (rows)

$$A^{-1}$$

$$= = A^T$$

SUBJECT: _____

DATE: _____

ABD
mostafa
en
e

Identity matrix

$$A = AI \Rightarrow I =$$

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Eigen decomposition

لارج مكون

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \lambda = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Eigenvalues

$$A\lambda = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} = 2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = 2\lambda$$

$$A - \begin{bmatrix} 7 & 3 \\ 3 & -1 \end{bmatrix} \rightarrow 2I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} 2 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

$$A - 2I = \begin{bmatrix} 7 & 3 \\ 3 & -1 \end{bmatrix} \rightarrow \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 7-2 & 3 \\ 3 & -1-2 \end{bmatrix}$$

$$\det \begin{bmatrix} 7-2 & 3 \\ 3 & -1-2 \end{bmatrix} \xrightarrow{\text{ذيل}} \begin{bmatrix} -1 & 3 \\ 3 & -9 \end{bmatrix}, \begin{bmatrix} 9 & 3 \\ 3 & 1 \end{bmatrix}$$

$$\frac{2}{2-62-16=0} (2-8) (2+2)=0$$

SUBJECT:

DATE:

• SVD

Singular Values
singular Vectors

في حال (A) مربع (Not square) فإنه يعطى

$$A = M \times n$$

$$A = U D V^T$$

$$U = M \times M$$

$$D = M \times n$$

$$V = n \times n$$

$T = T$ transpose

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

$$A^T A = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} = \begin{bmatrix} 17 & 22 & 27 \\ 22 & 29 & 36 \\ 27 & 36 & 45 \end{bmatrix}$$

$$\det((A^T A - 2I)) = \begin{bmatrix} 17-2 & 22 & 27 \\ 22 & 29-2 & 36 \\ 27 & 36 & 45-2 \end{bmatrix}$$

$$= 2^3 + 91 \cdot 2^2 - 542 \cdot 50 \quad (0 \leq A^T A \leq 1)$$

$$2 = 0.0597, 0.4$$

SUBJECT: _____

DATE: _____

Enas
ABD
Mostafa

Moore-Penrose Pseudoinverse

$$A^+ = V D^+ U^T$$

D
U^T

diagonal reciprocal
Transpose

① ← reciprocal ١ - (عكس)

Principal Component Analysis (PCA)

① Standardization

② Covariance matrix computation

③ دلالة المatrix (العلاقة) معيارية

وهي القيمة المعاوقة

$$A = \begin{bmatrix} 5 & 5 \\ -1 & 7 \end{bmatrix}, \text{ find SVD}$$

(Solve)

$$\textcircled{1} A^T A = \begin{bmatrix} 5 & -1 \\ 5 & 7 \end{bmatrix} \begin{bmatrix} 5 & 5 \\ -1 & 7 \end{bmatrix} = \begin{bmatrix} 26 & 18 \\ 18 & 74 \end{bmatrix}$$

$$A^T A - 2I = 0 \rightarrow \begin{vmatrix} 26-2 & 18 \\ 18 & 74-2 \end{vmatrix} = 0$$

$$2^2 - 100 \cdot 2 + 1600 = 0$$

$$\therefore (2-20)(2-80) = 0$$

$$\boxed{\begin{array}{l} 2 = 20 \\ 2 = 80 \end{array}}$$

$$\frac{|A^T A - I|}{2=20} = \begin{vmatrix} 5 & 18 \\ 18 & 54 \end{vmatrix} \begin{cases} | \\ | \\ 2=80 \end{cases} \begin{vmatrix} -54 & 18 \\ 18 & -6 \end{vmatrix}$$

Probability

Random Test

يُعرف عادةً التَّجْزِيَّةُ بِالْعَدَدِ الْمُوَجَّهِ إِلَيْهَا

هل ذرة المزدوج عارف الأرقام الموجودة لكن معرفته لما فيها أي

إلا اختياره

sample space (S)

كل الإحداثيات التي يمكن أن تتحقق في

ذُكرت على عددها وحصتها (العناصر) \rightarrow discrete ①

أو عدد غير محدود ولكن قابل للعدد

(interval) يحتوي على رأة أو وقوعة (متى) \rightarrow continuous ②

Sample Point. Possible Events

الختار

Random variable event \rightarrow sub set of sample space
هيsubset من مجموع

Frequency

الأحداث

(بالإنجليزية) → ↗

Probability Density function → (PDF) continguous

Cumulative Density Function → (CDF) continguous

Probability Mass Function → (PMF) discrete

* Continuous + Probability → يبقى لازم يكون المجموع من جميع القيم الممكنة متساوياً

* Variables Type → ① discrete النوع، التقديرات
الخطي، الوزن، العمر
② continuous

$$* \text{PDF} \rightarrow C X^2 \rightarrow \int C X^2 \rightarrow \frac{C X^3}{3}$$

$$* P(X \leq \frac{2}{3}) = \int_{-\infty}^{\frac{2}{3}} P(x) dx$$

افهموا بشرط $\frac{P(A \cap B)}{P(B)}$

$$P(\frac{1}{3} \leq X \leq \frac{2}{3}) = \int_{\frac{1}{3}}^{\frac{2}{3}} P(x) dx$$

$$* \text{Bernoulli} \rightarrow \{0, 1\} \quad E(x) = p$$

$$* \text{Expect value} \quad \text{لما زادت القيم} \quad E(x) = \sum x P(x)$$

* covariance

يسير على قوة الارتباط الخطى بين المتغيرات

وكم هذه المتغيرات

$$\text{cov}(X, Y) = E(X - E(X)) \{E(Y - E(Y))\}$$

The correlation coefficient

يسمى معامل الارتباط أيضاً معامل الارتباط الخطى (الذى يقاس

العلاقة الخطية بين متغيرين).

$$r_{XY} = \frac{\text{cov}(X, Y)}{\sqrt{D(X)} \sqrt{D(Y)}}$$

information Theory

استخدم شانون بشكل دينامي ذوية المعاملات

لدراسة مسائل الاتصال وقدم الوسيط العلمي والكتاب

للعلوم ولأول مرة أقترح مفهوم انتروبيا المعلومات

information Quantity

ال فكرة الأساسية لنظرية المعلومات

هي أن عند ما يقع حدث غير محتمل ، فإنه يحدث توفر معلومات

أكثـر من حدث محتمل جداً " بمعنى هناك معلومات غير معلومـة .

$I(X) = -\sum p_i \log_2 p_i$

فعدم مارسالها يوفر لي مساحة من المعلومات .

$$\text{when } P_1 > P_2 \rightarrow f_{P_1} < f_{P_2}$$

$$\text{when } P = 1 \rightarrow f(P) = 0$$

$$\text{when } P = 0 \rightarrow f(P) = \infty$$

$$\log_2 \frac{1}{2} = -1$$

$$(2X) \log_2 \frac{1}{2} = -2X$$

$$I(X) = -\log_2 P$$

لو كان طبيعة الرسالة

information ENTROPY

المعلومات الواردة في المصدر هي متوسط

عدم يقين من حل ملحوظ هو ممكن للوسائل المرسلة من المصدر

كل مسح قائم بـ P probability يتآثر المسح في قيمة

$$\text{المسح على هو } -\log$$

Numerical calculation

الحساب العددي يشير إلى طريقة وعملية استخدام المعلمات

لحل حلول التقريريات للمسائل الرياضيات والخدمات

وتشكلت من النظريات ذات صلة، عملية حل المسائل العددية

مع أجهزة الكمبيوتر هي على النحو الآتي :

① Problem analysis

تحليل المسألة

② Mathematical Model

نموذج رياضي

طريقة الحساب العددي

④ Programming design

تصميم البرنامج

نتيجة الحساب بالكمبيوتر

Overflow and Underflow

Underflow

يحدث تجاوز عند ما يتم تقرير رقم يقارب إلى الصفر تجاه رقم العدد الأخر

تظهر العبر من الوظائف ما مختلف نوعها تكون وسيطانها صفر

Overflow

تجاوز السعة

يحدث التجاوز عند ما يتم تقرير عدد كبير على

٥٥ - اضافه عاوه ماتتناسب العمليات في اون

تصبح هذه القيمة الالانهاية غير رقمي

The large Number

يتطلع العدد العيني

$$a \gg b, a+b = a,$$

عندما

يمكن للكمبيوتر تهديد السقف الراهن والقف السفلي عددياً

Negative Large Number

Large Number

Large Number

SUBJECT: _____

DATE: _____

condition number

رقم الشرط يشير إلى سرعة تغير الالة

مع الم忽ر يتم تغيير الراجل

optimization Problem

مشكلة التحسين تسمى تغيير

الـ x للنهاية أو التكبير $f(x)$ حالة يمكن التعبير عنها

$$\text{When } (x) = (x_1, x_2, \dots, x_n)^T \in R^n$$

* تشير إلى باعتبارها الالة الحرف أو المبدأ التوجيهي

و كذلك تكلفة أو دالة خسارة أو دالة خطأ تقليلها

$$g_i(x) \geq 0 \quad i = 1, 2, \dots, M \quad \text{قيود عدم المساواة}$$

$$h_i(x) = 0 \quad i = 1, 2, \dots, p, \quad \text{قيود مساوية}$$

classification of optimization Problemsconstraint optimization

يستخدم التحسين الالة في المعرفة تحت جميع القيم الممكنة

ليس - ما تزعم فيه بدلالة من ذلك قد تزعم في ذلك

feasible Point

لـو يستغل على شرط تحـتـ قـيم مـعـيـنـ

Sermat

نـظـرـةـ فـرـمـةـ

critical Point

$$f(x) = 0$$

يعـدـ

Lagrange Multiplier method

لـو شـرـطـ وـاـحـدـ بـضـرـبـ لـمـاـنـ يـهـ يـمـرـ بـ

$$f(x, y) = xy \quad \text{الـشـرـطـ} \quad x + y = 6$$

$$Z(x, y, \lambda) = xy + \lambda |8 - x - y| \quad 0 \leq \lambda$$

$$x + y = 6$$

$$\frac{\partial Z}{\partial x} = y - \lambda = 0$$

$$\frac{\partial Z}{\partial y} = x - \lambda = 0$$

$$\text{Point at } x^* = y^* = \lambda^* = 3$$

SUBJECT: _____

DATE: _____

Gradient Based Optimization Method (1)

تشرى إلى كيفية تغيير x لتحسين y قليلاً

نفس النقطة المزدوجة أو النقطة ذات الماء $\rightarrow f'(x) = 0$ اه أه

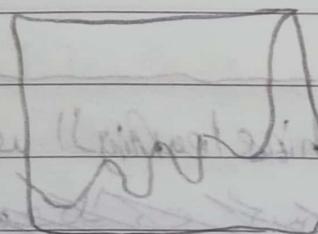
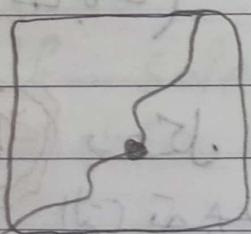
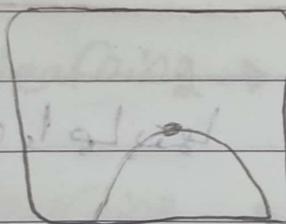
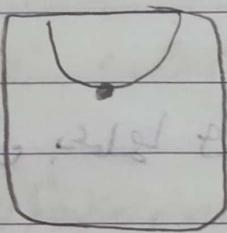
أقل من الصفر أزود المؤشر ، إذا كان أكبر من صفر أقل المؤشر

$x = 0$ حتى أنت عن

Gradient Based optimization Method (2)

تشير إلى نقاط محدبة المقصوى للدالة العددية

موجودة عند النقطة القافية



SUBJECT: _____

DATE: _____

* يوفر حل للمشاكل المعقدة

Machine Learning Algorithms complex \rightarrow more Features
 Θ columns

large amount of data \rightarrow More samples/observations

Data \rightarrow Learning algorithm \rightarrow Understanding

غالباً ما يتم دراسة (Machine Learning) في مجالات مثل العلوم الطبيعية والرياضيات

لدراسة و مراقبة الخوارزميات يقال أن الكمبيوتر يتعلم من

بيانات فيما يتعلق بمعنى فئات ليستخدم Learning Algorithms (نرتفع

ما تم ما دخل

HYPERParameters

قبل ما أبدأ أو أعمل على شيء يجب أن يكون فيها

تفاصيل زي الاعدادات (setting)

Parameters

التفاصيل بعملها و تعارفها وأهميتها

(ليجادلها)

بشكل عام بعد Machine learning هو الأنسنة للمسكلات

التي تؤدي بها ~~المسكلات~~ كمية كبيرة من البيانات

والآن نظر المعايير التي يمكن تحديدها

الآن

Machine Learning [ماشين لارننج]

① لما الأبعاد كثيرة يصعب على العقل البشري أن يحسبها

② لما يتبعه الاتا كثيرة

distribution function can't be determined

continuous learning

TYPES of machine Learning

① Supervised learning → from labeled dataset

متاح وقت كثير

② Unsupervised learning → from unlabeled dataset

متوسط الدقة
من محتاج وقت كثير (دقة عالية)

③ Semi-supervised learning → labeled, unlabeled

④ Reinforcement learning → updating the Policy

⑤ Self-supervised learning → يتم تدريب المفهود على التنبؤ بالمعنى في حالات مختلفة على الحالات السابقة

⑥ Contrastive learning → يتعلم عن طريق المقارنة / تنافس

الذكاء الاصطناعي والغوكسبلر
الفكرة المثلثية ← تدرب على التمييز بين زوج و المغشى

SUBJECT: _____

DATE: _____

(7) Generative learning →

Machine learning نوع من الـ

الذى يوجه فيه التدريج قيمه هدفها على انتهاى بيانات جديدة
 مصطلحه مجموعة بيانات معينة يمكن استعماله فى (الصور) الموسوع
 النص ، يتحقق صفوى جديدا فى حالة ان data قليل

Learning Rate

ما يغير بسرعة أو يقل update

$$y = Wx + b \quad \leftarrow \text{لـ } y, x \text{ لـ } W$$

$$\Delta W = -\text{Learning rate} * \text{gradient}(W)$$

$$\Delta b = -\text{Learning rate} * \text{gradient}(b)$$

$$\text{gradient } W = 2/N * \sum (X_i(y - \text{Pred}_i) - y_{\text{actual}})$$

$$\text{gradient } b = 2/N * \sum (y - \text{Pred}_i - y_{\text{actual}})$$

Machine learning Algorithms

خبرة

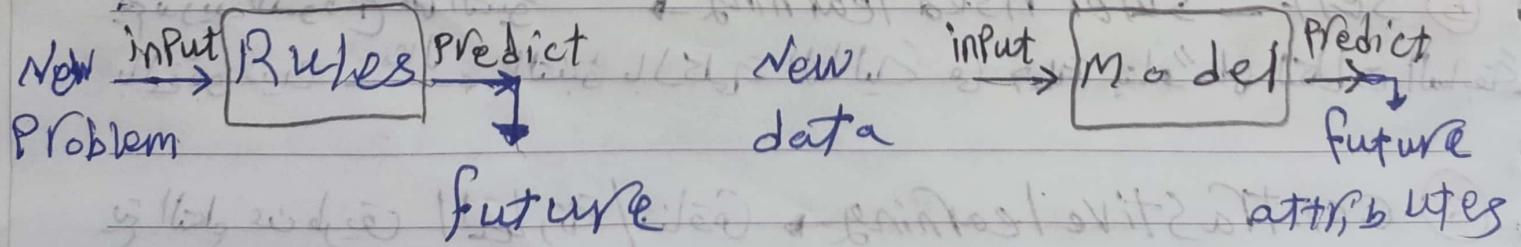
EXPerience

↓ summarize

بيانات

Historical data

↓ Train



SUBJECT: _____

DATE: _____

	Manual rules	Machine learning algorithms
High complexity of rules	Simple questions	Rule-based algorithms
Low	Small	Large

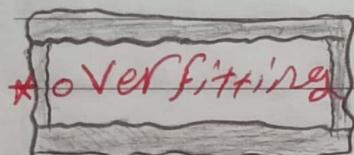
Classification →

(أصناف)

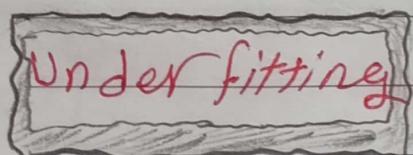
Regression →

يبحث عن دالة الاتجاه

Clustering → unlabeled data (غير مصنف)



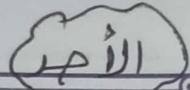
يحدث عندما يكون الـ Model "مرئ" يوحى إلى تلبيس عملية الـ Learning وبالتالي يمرت ضعف في النتائج (زيادة في وقت التعلم learning time)



عكس Overfitting يحدث عندما يكون الـ Model بسيط جدًا لتعلم البنية الأساسية للبيانات

Learning Model (أ) أقوى هو المزبور (B) ميزات أشمل لا Learning (C) تعليم القبور على الـ Model

على سبيل المثال ← تعليم تنظيم المعاملات الفاصلة



SUBJECT:

10/9/2023

DATE:

Dr/Mostafa

Section 4

محاولات وتجربة

Trial

The agent learns by trial and error

يتعلم من التجربة الأخطاء ويعد لها وعدها
ثم يتلقى دعوة فعل في كل المكافأة نوعية من البيئة بناءً على نوعها

current state

① يلاحظ

Actions

② يختار على أساسها الحالية / قواعدها

Reward:

③ تحصل على دعوة هي مكافأة من قاعدة البيئة عن عملها

state transition: new state based on the agent's action

Machine learning Process

- ① Data Preparation: تتعديل البيانات Preprocessing بحيث تكون البيانات في شكل متسق على كل البيانات
- ② Data cleaning: إكمال المفقودات في البيانات وتحوين البيانات إلى فيها (فجوات)
- ③ Feature extraction and selection: تبسيط البيانات
- ④ Model training: بعد ما تم جعل البيانات في شكل متسق على التعلم يُدخلها على التعلم
- ⑤ Model evaluation: فيبدأ أسلوب دوّننا عارف الإجراء على علماً تُعرّف بـ Koios ولا لا (ما يختار)
- ⑥ Model development and integration: ننشر النموذج طفلاً كان قمت هذه العملية بنهاية

- * data dimension Reducting

يقال ذو الأبعاد
فيمثل كل خط مع الأبعاد
- * data standardization

توحيد البيانات
- * Missing Value

مفقون (قيمة مفقودة)
- * in Valid Value

قيمة غير صالحة
- * mis specified value

قيمة خاطئة
- * miss Pelling

خطأ مطبعي
- * dependent attributes

ذكر اخر
- * in correct format

تنسيق غير صحيح
- * invalid duplicate Items

عناصر مكررة غير صالحة

* Data Pre Processing Operations

- ① Data filtering ^{Types}
- ① Time Period فترة معينة
 - ② Attributes خصائص معينة
 - ③ Sampling random عشوائية

من البيانات المختلطة

* هي عملية اختيار مجموعة فرعية من البيانات
ال剩idue المختلطة

الهدف تقليل حجم مجموعة البيانات أو دواؤ الذهاب

غير ذات صلة

② Data loss ^{hidden} هي عملية فقدان البيانات لأسباب مختلفة
مثل فعل الأذى، خطأ البرامج للتعامل مع فقدان البيانات
يمكن استخدام الآتي:

→ ① Data back up أفضل طريقة للتعامل مع فقدان
البيانات

→ ② Data interpolation فقد بيانات قليلة

→ ③ Data augmentation إنتاج بيانات جديدة من
البيانات المتاحة وهذا يمكن أن يساعد على زيادة دعم التعلم

→ ④ data imputation فقد بيانات كثيرة

data imputation

① mean imputation

١) ياسبىء القيمة المقصودة بمتوسط
القيمة المتاحة لكل العبرة

② Median imputation

٢) ياسبىء القيمة المقصودة بمتوسط
يتموسط القيمة المتاحة

③ Mode imputation

٣) ياسبىء القيمة المقصودة بمعنط
القيمة المتاحة

Feature selection Methods

Target ← المخرجات / الهدف
ميزة

① Filter method → output features

(Filter method process)

Traversal → selecting the best feature → learning → Model
all features → best feature algorithm evaluation
أ. اختيار جميع (Traversal)
subset → خوارزمية
التصنيع → التعلم → أ. اختيار (Traversal)
ميزة → المخرجات / الهدف

② Wrapper feature selection method

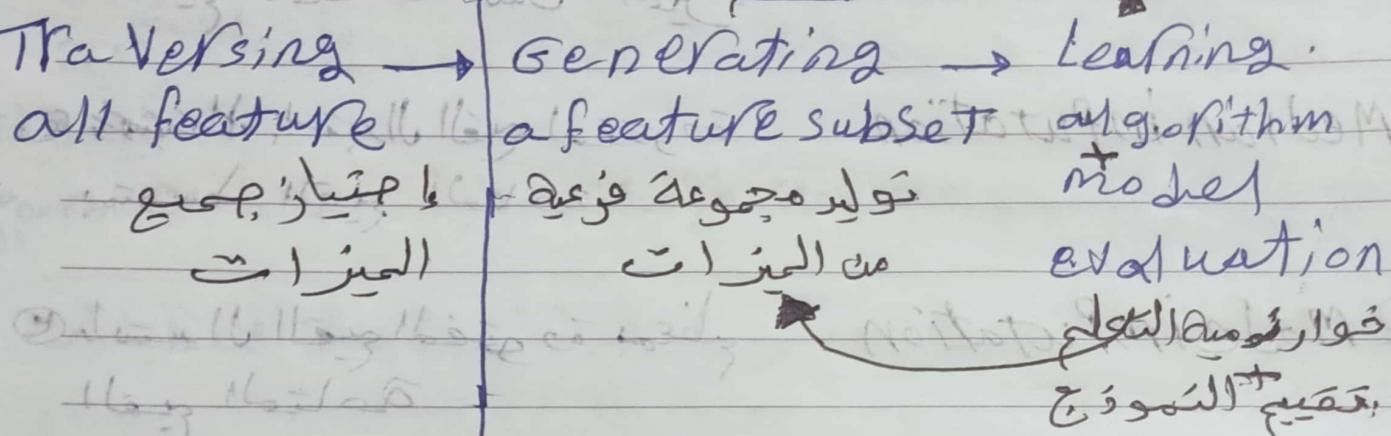
يسخرم ومحو عما فرغ من العبرة في التفويج

Wrapper method process

Traversal → Generating → Learning → Model
all features → a feature subset → algorithm → evaluation
أ. اختيار جميع (Traversal)
subset → خوارزمية
التعلم → أ. اختيار (Traversal)
ميزة → المخرجات / الهدف

③ Embedded feature selection:

جنيحة Learning دس وبيجات
Embedded methods Process



① import Pandas as pd

② data = { 'x': [1, 2, 3], 'y': [11, 22, 33] }

③ df = pd.DataFrame(data)

④ print(df)

The output →

x y

0 1 11
1 2 22
2 3 33

(1)

0	1	11
1	2	22
2	3	33

SUBJECT: _____

DATE: _____

① import Pandas as pd

② data = {'x': [1, 2, 3], 'y': [11, 22, 33]}

③ df = pd.DataFrame(data)

④ print(df.loc[df['x'] > 1])

The output →

	x	y
1	2	22
2	3	33

لو كذا اعمود وعاوز أطبع عمودين فقط

df2 = df[['x', 'y']] ← هوند سطر بع السطر الـ ٢

أطبع العمودين الـ ١ و ٢ فقط

cols = ['x', 'y'] ← حل تاني

df2 = df[cols]

لوعاوز أطبع هـ

① Import Pandas as Pd

② data = { 'x': [1, 2, 3], 'y': [11, 22, 33] }

③ df = Pd.DataFrame(data)

④ cols = ['x', 'y']

⑤ df2 = df[cols]

⑥ print(df2.loc[[0, 2]])

لوعاوز أطبع المدى

الأول (0)

الثالث (2)

The output is x y

0	1	11
2	3	33

data.insert(2, "Age", [21, 23, 24], True)

→ (قم بعموره الثالث)
القيمة

لوهمنه العودة إلى ما كان

~~data.insert("Age", [23, 24])~~

SUBJECT: _____

DATE: _____

① import · Seaborn as sns

② import Pandas as pd

فـ الـ مـ لـ الـ مـ لـ الـ

```
③ data = sns.load_dataset('diamonds')
```

④ Print (data)

لـ عـاـزـفـ عـلـ فـيـ الـ إـنـ سـلـ يـعـهـ دـمـ. (in place) (is)

الصيغة الافتتاحية

```
df.fillna(130, inplace=True)
```

الحادية الفاضيَّةُ سَكَّانُهَا وَهُنَّ مِنْ أَقْرَبِهِمْ

لوعاوز أديف ~~مغوف~~ - append

data. - append ({`col1':50, `col2':100, `col3':22})

```
df[["calories"]].fillna(130, inplace=True)
```

ـ محمد العودة إلى بيته على

```
x=df[ "calories" ].mean()
```

جاء المَوْلَى

```
x=df[["calories"]].median()
```

حصا بـ الـ وـ سـ

`x = df[["Calories"]].Model()`

الله كثیر تکراراً

SUBJECT: _____

DATE: _____

for x in df.index:

if df.loc[x, "العمو^ف"] > 120:
↓
↓ الهدف

df.loc[x, "العمو^ف"] = 120

df = pd.read_csv('data.csv')

df.plot()

plt.show()

(f55:55A'col:1) col:1 - .stab

(col:1=actual) valit.] "zetales" [1]

case 1605: valit.]

else: valit.

(lambda:1["zetales"]) 76 = x

else: valit.

(lambda:1["zetales"]) 76 = x

else: valit.

(lambda:1["zetales"]) 76 = x